Ignacio Méndez Alvarez
Diego Soto Flores

26 de marzo de 2026

Laboratorio 7

Task 1

Pregunta 1.1

1. El data augmentation es una forma de generar nuevos datos para un modelo cuando tenemos datos limitados, la forma de generar estos datos es tomar los datos originales que tenemos y se realizan algunas modificaciones pequeñas para que todavía puedan ser usadas durante el entrenamiento. En si no estamos inventando datos desde cero, en este caso tomamos las radiografías originales y les hacemos unas modificaciones que, si puedan ocurrir durante la práctica, no agregamos estructuras extras o inventamos alguna enfermedad. Es como estudiar un caso clínico, pero desde distintas posiciones y brillo, es el mismo caso, pero se ve distinto.

2. Transformación 1: rotaciones de la radiografía de tórax, se pueden aplicar pequeñas rotaciones de las radiografías originales. Esta transformación es valida porque hasta cierto punto una radiografía si puede cambiar de alguno dependiendo de como fue tomada, entonces si seria un caso posible y valido. Además, estas rotaciones ayudan al modelo a conocer distintos ángulos anatómicos que pueden ser útiles para un modelo más robusto.
   Transformación 2: Ajustes de brillo y contraste, en radiografías puede haber distintos brillos y contrastes dependiendo de la configuración de la máquina, no todas son iguales. Si estos cambios son moderados el modelo puede aprender a tratar distintas intensidades.
   Transformación 3: Traslaciones y recortes leves, se pueden hacer algunas traslaciones y recortes siempre y cuando no sean drásticos porque no se puede eliminar información clínica importante. Estas cambios simulan variaciones en la posición del paciente y evita que el modelo solo pueda con una posición especifica.
   Transformación invalida: Volteo de imagen, cambiar el posicionamiento de izquierda a derecha no es valido en el caso de radiografías ya que en medicina es importante el lado del paciente, si cambiamos esto el modelo puede aprender algo que no es posible en la realidad.

3. No, el data augmentation no es suficiente ya que este solamente nos brinda más datos cuando tenemos una cantidad limitada, pero no a generalizar el modelo. Otros factores que ayudan son las etiquetas, el balance de clases, la arquitectura elegida, regularización, tamaño y técnica para evitar el sobreajuste. Es decir, si queremos un modelo que generalice bien no solamente nos basamos en la calidad de los datos sino en la calidad de construcción del modelo.

Pregunta 1.2

4. El sobreajuste empieza después de la época 10, ya que en ese punto tanto el entrenamiento como la validación estaban bajando su perdida. En la época 15 ya se puede ver que solamente el entrenamiento estaba bajando y fue un bajada bastante significativa desde la época 10 a la 15, por otro lado, la validación empezó a subir su perdida, indicativo de sobreajuste. Esto se termina de confirmar en las siguientes épocas donde el entrenamiento

prácticamente no tiene error cuando la validación solamente aumenta drásticamente. Evidencia de que el modelo solo memoriza los datos de entrenamiento.

5. Dropout: El dropout apaga de manera aleatoria algunas neuronas durante el entrenamiento. Esto hace que el modelo no depende de algunas combinaciones específicas de neuronas. De manera matemática este reduce la adaptación de combinaciones y hace más difícil que el modelo memorice detalles irrelevantes. En la curva hace que el entrenamiento baje más lento pero el verdadero impacto es en la validación porque lo hace más estable y que no suba tan rápido.

   Regularización L2: La regularización l2 penaliza pesos muy grandes en la función de perdida, esto hace que el modelo encuentre soluciones más simples. Matemáticamente esto agrega un termino de penalización sobre la magnitud de los parámetros, reduciendo la complejidad efectiva del modelo. En la curva esto afecta al entrenamiento ya que no baja tanto, pero hace que la validación no se dispare tanto.

6. Un modelo sobreajustado puede parecer muy bueno porque tiene muy buenos resultados en el entrenamiento, pero este puede fallar cuando ya se le pasan radiografías distintas de las del entrenamiento. Además, el modelo no necesariamente va a funcionar en un solo lugar entonces cualquier pequeño cambio puede generar falsos negativos, no detectar neumonías reales, retrasando el tratamiento y brindando un diagnostico incorrecto. También este modelo puede producir falsos positivos, generando alarma innecesaria en el paciente. Es decir, un modelo sobreajustado puede generar estos valores falsos que ponen en riesgo total la salud del paciente.

Pregunta 1.3

7. $Accuracy = \frac{700}{700+150} = \frac{700}{850} \cong 82.35$

   El accuracy naive seria de 82.35, esto revela que el accuracy de 94% es engañoso porque no esta balanceado. Es posible que le valor de 94% sea más alto por el predominio de la clase Normal comparada con la clase de neumonía. Por eso este 94% no es confiable para diagnosticar neumonía.

8. En problemas médicos y con clases desbalanceadas, el accuracy puede ocultar el desempeño real sobre la clase más importante, que en este caso es la neumonía. Por eso es importante usar otras métricas, en este caso F-1 score y Recall son más informativas. El recall para neumonía indica la proporción de casos enfermos que sí logra detectar el modelo. Esto es crucial porque un falso negativo significa un paciente que no recibe tratamiento. El F-1 score es importante porque equilibra Recall y Precisión, es decir no solamente nos interesa detectar muchos casos, sino que estas detecciones tengan buena calidad. En medicina estas métricas son más importantes porque evalúan directamente que tan seguro es el sistema para apoyar decisiones.

9. El valor de 94% de accuracy es un valor muy bueno, pero por si solo no es suficiente para determinar que el modelo es funcional. Nuestro objetivo es detectar neumonía, pero como nuestros datos están desbalanceados, van a salir más radiografías normales que casos de neumonía, por lo tanto, esta métrica es muy global ocultando errores. Por eso evaluamos el modelo con distintas métricas que nos brinda más seguridad de que el modelo si funciona y puede ser aplicado en la vida real. No tratamos de acertar muchos casos, sino minimizar casos reales.

Task 2

Pregunta 2.1

1. No estoy de acuerdo con el desarrollador porque, aunque ImageNet tenga imágenes de cosas muy distintas como animales o carros, las primeras capas de una CNN no aprenden objetos como tal. Las primeras capas aprenden patrones básicos como bordes, texturas, contrastes y formas simples. Además, estos patrones existen también en radiografías, aunque sean en escala de grises. Al final, una opacidad en un pulmón también es un cambio de textura o intensidad que el modelo puede captar. Por esto es que el transfer learning sí tiene sentido, porque aprovecha ese lenguaje visual básico ya aprendido y no empieza desde cero.
2. Entrenar desde cero no solo es caro en términos computacionales, sino que también tiene un costo fuerte en tiempo y riesgo. Para una startup como MediScan Guatemala, el tiempo al mercado es importante, y entrenar desde cero con un dataset limitado puede tomar mucho más tiempo y puede llegar a dar peores resultados. Además, hay un riesgo alto de overfitting porque no hay suficientes datos. También entra el tema del talento, porque se necesita gente muy especializada para diseñar y ajustar bien un modelo desde cero, mientras que con transfer learning se reuce esa complejidad y se puede avanzar más rápido con un equipo más pequeño.
3. Sí hay casos donde sí valdría la pena entrenar desde cero pero no es algo que consideraría siempre. Por ejemplo si tuviera varios datos de radiografías variados y de buena calidad, ahí ya tendría más sentido porque el modelo podría aprender directamente de ese dominio sin depender de otro. Otro caso es si el problema fuera muy específico o muy distinto a lo que normalmente se ve en ImageNet. Pero en un escenario como este con datos limitados entrenar desde cero sería muy complicado.

Pregunta 2.2

1. Yo recomendaría la opción A. Con solo 800 imágenes y además siendo un dominio distinto, el riesgo de dañar lo que ya aprendió el modelo es bastante si se entrena todo. Las capas base ya tienen una idea general de patrones visuales que siguen siendo útiles, entonces tiene más sentido mantenerlas estables y solo entrenar la parte final para adaptarlo al problema de neumonía. La lógica de esto es evitar que el modelo olvide lo que ya sabe mientras aprende algo nuevo con pocos datos, porque si no, en lugar de mejorar puede empeorar.

2. Si se usa la opción B con una tasa de aprendizaje alta en toda la red, el riesgo es que el modelo empiece a perder todo lo que había aprendido antes. Este fenómeno se llama catastrophic forgetting. Básicamente, los pesos cambian demasiado rápido y el modelo deja de reconocer patrones generales que ya tenía bien aprendidos. En el entrenamiento se vería como resultados inestables, por ejemplo, la pérdida sube y baja mucho o el modelo no mejora en validación, aún si al inicio parecía que iba bien.
3. Sí, si ya se tuvieran 50,000 radiografías cambiaría bastante la estrategia. Con más datos, ya tendría sentido empezar a descongelar capas poco a poco y ajustar más partes del modelo, porque ahora sí hay suficiente información para que aprenda mejor del dominio médico. No necesariamente entrenaría todo de un solo, pero sí haría un fine-tuning progresivo, empezando por las capas más altas. La idea es aprovechar mejor los datos nuevos sin perder lo bueno que ya traía el modelo preentrenado.

Pregunta 2.

1. Sí es viable reutilizarlo pero no por completo. Las primeras capas del modelo sí se pueden aprovechar porque ya aprendieron cosas básicas como bordes, contrastes y formas, que también aparecen en radiografías de muñeca. Pero las capas más profundas y el cabezal están muy enfocados en detectar neumonía en pulmones, entonces eso sí habría que cambiarlo. Esto significa que lo general sirve, pero lo específico del problema anterior no podría reutilizarlo.
2. Un plan sería, primero cambiar completamente el cabezal para que clasifique fracturas en lugar de neumonía. Segundo, entrenar solo ese cabezal dejando congeladas las capas base, usando una tasa un poco alta como 1e-3 para que aprenda rápido el nuevo task. Tercero, ya cuando eso esté estable, empezar a descongelar algunas capas superiores del modelo y entrenar con una tasa más baja como 1e-5 para ajustar mejor al nuevo tipo de imagen sin arruinar lo que ya sirve. En resumen sería como un fine-tuning progresivo.
3. Habría riesgo porque un modelo mal adaptado puede dar diagnósticos incorrectos y eso afecta directamente a pacientes. No es solo un error técnico, porque puede significar que una fractura no se detecte o que se marque algo que no es. Por eso no se puede reutilizar sin validar bien. Como proceso de validación mínimo haría una evaluación con un conjunto de prueba nuevo y representativo, revisaría métricas clave, y además incluiría validación con médicos reales para ver si las predicciones tienen sentido en la práctica. Sin eso, desplegar el modelo sería muy riesgoso.